

Curso BigQuery (GoogleSQL) - Proyecto Final

Enunciado, requisitos, entregables y rúbrica de evaluación

Docente	Tabita Pisco Ostos
Fecha de publicación	viernes 13 de febrero de 2026
Fecha límite de entrega	domingo 01 de marzo de 2026 - 23:59 (hora Lima)
Canal de entrega	Classroom
Modalidad	Individual

Importante: el proyecto debe ejecutarse y quedar almacenado en BigQuery dentro de la cuenta del estudiante (dataset propio).

1. Objetivo

Construir una solución analítica end-to-end en BigQuery: desde datos públicos, hasta la generación de tablas finales que respondan a un caso de uso de negocio.

2. Alcance y reglas

- El desarrollo debe realizarse en BigQuery y quedar en un dataset propio del estudiante (mismo proyecto, misma ubicación).
- Se deben usar al menos 3 fuentes (tablas/datasets públicos o archivos públicos) que puedan relacionarse por al menos una clave común (por ejemplo: país, fecha, categoría, producto, usuario, etc.).
- Debes evidenciar relación entre fuentes mediante JOINS (mínimo 2 tipos distintos, por ejemplo INNER y LEFT). Puedes usar RIGHT/FULL cuando aplique.
- No se aceptan entregas solo con consultas sueltas: el proyecto debe incluir creación de tablas y vistas en el dataset.
- Se permite usar material del curso como referencia, pero el SQL debe estar ordenado, comentado y ejecutable (sin pasos manuales ocultos).
- El resultado debe tener sentido de negocio: métricas, comparativos, rankings o tendencias claramente interpretables.

3. Caso de uso

Define un caso de uso claro y medible. Debe responder:

- ¿Qué problema resuelves?
- ¿Para quién (área/usuario) está pensado el reporte/análisis?
- ¿Qué métricas o indicadores entregarás y con qué periodicidad?
- ¿Qué decisiones habilita tu salida (acciones posibles)?

Ejemplos (referenciales):

- Performance de e-commerce por país y mes: usuarios, transacciones, ingresos, ticket promedio, top productos.

- Evolución de demanda por categoría y temporada: volumen, crecimiento vs mes anterior, categorías top/bottom.
- Calidad de eventos digitales: funnels, tasas de conversión, cohortes de usuarios por periodo.

4. Fuentes de datos (mínimo 3)

Selecciona al menos tres fuentes públicas que puedas relacionar. Recomendación: usar datasets públicos de BigQuery para simplificar accesos y permisos.

Sugerencias de fuentes (elige las que hagan sentido para tu caso):

- GA4 sample e-commerce: `bigquery-public-data.ga4_obfuscated_sample_ecommerce` (tablas `events_*` con ARRAY/STRUCT, ideal para UNNEST).
- theLook eCommerce: `bigquery-public-data.thelook_ecommerce` (ventas, productos, usuarios, eventos).
- Códigos de países (ISO 3166-1): `dataset country-codes` en BigQuery Public Data (útil para enriquecer por continente/región).
- COVID-19 Open Data: `bigquery-public-data.covid19_open_data` (fechas y país para análisis temporales).

Nota: no estás obligado a usar estas fuentes; puedes elegir otras, siempre que sean públicas y se relacionen entre sí.

5. Arquitectura requerida (RAW -> STG -> MARTS)

Tu modelo debe seguir esta estructura mínima:

Capa	Propósito
RAW	Copia controlada (subset) de cada fuente. Sin lógica compleja; solo normalización mínima de tipos/nombres.
STG / VIEWS	Transformaciones reusables: UNNEST, limpieza, joins base, columnas derivadas, estandarización de claves.
MARTS (FINAL)	Tablas finales para consumo analítico: KPIs, rankings, agregaciones y estructuras listas para BI.

Convención sugerida de nombres (opcional, pero recomendado): raw_*, stg_*, mart_*

6. Requerimientos técnicos (obligatorios)

Tu entrega debe evidenciar lo siguiente (checklist):

- Dataset propio creado en la ubicación correcta (recomendado: US si tus fuentes públicas están en US).
- Tablas RAW: mínimo 3 (una por fuente) como copia/subset de datos.
- Vistas STG: mínimo 2 (transformaciones intermedias).
- Tablas finales (MARTS): mínimo 3, con resultados de negocio.
- ARRAY/STRUCT: uso de UNNEST() y al menos un campo final con ARRAY_AGG(STRUCT(...)) o STRUCT anidado con sentido (por ejemplo, top N dentro de un KPI mensual).
- Funciones analíticas: al menos 2 usos (por ejemplo RANK / ROW_NUMBER / LAG / LEAD).
- Scripting: entregar un script o stored procedure que use DECLARE (y parámetros) para controlar el periodo, partición o un filtro clave.
- Buenas prácticas: nombres consistentes, comentarios, control de costos (LIMIT, filtros por fechas, particionado/clustering si aplica).

7. Tablas finales mínimas (3 MARTS)

Debes entregar al menos 3 tablas finales. Puedes proponer otras, siempre que tengan sentido para tu caso de uso. Ejemplos:

- `mart_kpi_pais_mes`: KPIs por país y mes (usuarios, transacciones, ingresos, ticket promedio, crecimiento).
- `mart_top_entidades_mes`: top N productos/clientes por mes, usando `ARRAY_AGG(STRUCT(...))` para almacenar el ranking en un campo anidado.
- `mart_alertas_o_anomalias`: variaciones relevantes vs periodo anterior (LAG/LEAD), detección de caídas/subidas y banderas (flags).

Nota: al menos una tabla final debe incluir un campo tipo ARRAY/STRUCT.

8. Entregables

Sube a Classroom los siguientes elementos:

1. SQL ejecutable (.sql) con secciones claras: 01_RAW, 02_STG_VIEWS, 03_MARTS y 04_SCRIPT/PROCEDURE.
2. Documento breve (README, Word o PDF): caso de uso, fuentes, diagrama lógico RAW -> STG -> MARTS, explicación por pasos y decisiones de modelado.
3. Evidencias (capturas): datasets/tablas creadas, esquema de columnas (incluyendo ARRAY/STRUCT), partición/clustering si aplica, y muestra de resultados.

9. Rúbrica de evaluación (100 puntos)

Criterio	Puntaje	Qué se espera (guía)
Caso de uso y coherencia del análisis	20	Caso claro, medible y consistente con las tablas finales. KPIs alineados a decisiones de negocio y narrativa entendible.
Modelado y relación de fuentes (JOINS)	20	Fuentes correctamente relacionadas, claves consistentes, joins justificados y controles de duplicidad.
ARRAY/STRUCT (UNNEST y estructuras)	20	Uso correcto de UNNEST y construcción de estructuras anidadas (<code>ARRAY_AGG + STRUCT</code>) con sentido analítico.
Scripting con DECLARE / automatización	15	Script o procedure parametrizable (DECLARE) para recalcular periodos o ejecutar cargas de forma repetible.

Proyecto Final - Curso BigQuery (GoogleSQL)

Buenas prácticas y performance	10	SQL ordenado y comentado, filtros para reducir escaneo, particionado/clustering cuando aplica, nombres consistentes.
Documentación y evidencias	15	README/PDF claro y completo, capturas suficientes, y pasos replicables.
TOTAL	100	